

Relatório de Desenvolvimento e Análise Ant-Clustering

Vitor Cardoso Burgarelli¹

¹Centro de Ciências Tecnológicas - Universidade Estadual de Santa Catarina (UDESC)

vcburgarelli@gmail.com

Resumo. *Este trabalho apresenta a implementação e a análise de um sistema de agrupamento inspirado no comportamento de limpeza de formigueiros por formigas reais (ant-based clustering). São abordados dois cenários: o agrupamento de itens homogêneos (corpos de formigas mortas, sem atributos distintivos) e o agrupamento de dados heterogêneos bidimensionais, organizados em 4 e em 15 grupos. O sistema foi modelado como um agente reativo simples que se desloca em um ambiente bidimensional toroidal, decidindo pegar ou largar itens com base em probabilidades derivadas da similaridade local percebida em sua vizinhança. Os experimentos foram conduzidos com os parâmetros k_1 , k_2 e α ajustados para cada cenário. Os resultados mostram a formação progressiva de aglomerados coerentes com os grupos originais dos dados, confirmando a viabilidade da técnica como método de agrupamento não supervisionado.*

1. Introdução

O algoritmo de *Ant-Clustering* é uma técnica de inteligência artificial inspirada no comportamento de insetos sociais, aplicada para resolver problemas de agrupamento de forma distribuída. O modelo utiliza agentes autônomos (formigas artificiais) que se movem em um ambiente discreto, decidindo pegar ou largar itens com base na densidade ou na similaridade dos elementos presentes em sua vizinhança perceptiva local. Os fundamentos teóricos e as regras de transição de estado deste modelo são fortemente baseados nos conceitos clássicos descritos por [Lumer e Faieta 1994] e nos materiais de apoio da disciplina [Parpinelli 2026].

Este relatório documenta a implementação computacional e a avaliação prática desse algoritmo em dois cenários de experimentação. O primeiro foca no agrupamento de itens homogêneos (sem atributos além de sua própria existência), utilizando um ambiente em formato de grade $N \times N$, populado com 600 itens e operado por 50 agentes de coleta. O segundo cenário estende o mecanismo para o agrupamento de dados heterogêneos, atuando como um método de *clustering* não supervisionado para conjuntos de dados sintéticos organizados em 4 e 15 grupos. Nesta etapa, a distância Euclidiana foi adotada como métrica de dissimilaridade para guiar a tomada de decisão dos agentes.

Além da análise dos agrupamentos resultantes e das formulações matemáticas das ações dos agentes, este relatório também aborda as adaptações arquiteturais realizadas durante o desenvolvimento da solução (como a migração da lógica de execução principal da linguagem Python para C), necessárias para otimizar o tempo de processamento das simulações.

2. Metodologia de Desenvolvimento

O ambiente de simulação é estruturado como uma matriz bidimensional discreta que opera sob uma topologia toroidal, conectando as bordas opostas da matriz para evitar efeitos artificiais de limite espacial. Inicialmente, itens e agentes são distribuídos de forma aleatória e uniforme pela grade, garantindo ausência de sobreposição espacial de itens e respeitando o limite estrito de um agente por célula. Durante a execução, o deslocamento dos agentes ocorre de forma estocástica para uma das quatro direções ortogonais adjacentes (cima, baixo, esquerda ou direita). Embora os itens no chão não atuem como obstáculos para a navegação, duas formigas não podem ocupar a mesma coordenada simultaneamente..

2.1. Agrupamento de Dados Homogêneos (Itens)

A dinâmica do sistema é controlada por valores inteiros que representam o estado atual de cada célula: 0 (espaço vazio), 1 (formiga morta/objeto), 2 (formiga viva descarregada), 3 (formiga viva sobreposta a uma formiga morta), 4 (formiga viva carregando uma formiga morta) e 5 (formiga viva carregando uma formiga morta e posicionada sobre outra formiga morta). A cada passo, a formiga inspeciona sua vizinhança dentro de um raio definido e, com base no número de objetos detectados ao seu redor, toma a decisão de alterar o estado da célula atual, seja coletando um item do chão ou soltando a carga que carrega.

As ações de coleta e depósito obedecem a uma função de probabilidade linear simples, baseada na proporção de itens em relação à capacidade máxima do campo de visão do agente (raio). Essas probabilidades, de pegar (P_{pegar}) e largar (P_{largar}) um objeto, são calculadas, respectivamente, da seguinte forma:

$$P_{pegar} = 1 - \frac{\text{objetos}}{\text{raio}} \quad \text{e} \quad P_{largar} = \frac{\text{objetos}}{\text{raio}} \quad (1)$$

2.2. Agrupamento de Dados Heterogêneos

Diferente do modelo homogêneo, os itens no agrupamento heterogêneo são instâncias compostas por vetores de atributos numéricos. Nesse cenário, a avaliação da vizinhança deixa de ser somente espacial e passa a depender das características dos dados. Para isso, o algoritmo calcula a Distância Euclidiana (d) entre o item em análise (i) e um vizinho (j), convertendo essa medida em uma métrica de Similaridade (S), onde α atua como um fator de escala para calibração. A partir disso, obtém-se a densidade local baseada em características (f), calculada como a média das similaridades dos N vizinhos detectados no raio de percepção do agente.

Com o valor de f estabelecido, a probabilidade de o agente interagir com a carga é descrita por funções não lineares, calibradas através dos parâmetros de limiar k_1 (para coleta) e k_2 (para depósito). O conjunto de equações que define a dinâmica completa de cálculos de distância, similaridade e as respectivas ações de pegar (P_{pick}) e largar (P_{drop}) é estruturado da seguinte forma:

$$d(i, j) = \sqrt{\sum (x_i - x_j)^2} \quad ; \quad S(i, j) = 1 - \frac{d(i, j)}{\alpha} \quad ; \quad f = \frac{1}{N} \sum_{j=1}^N S(i, j) \quad (2)$$

$$P_{pick} = \left(\frac{k_1}{k_1 + f} \right)^2 \quad \text{e} \quad P_{drop} = \left(\frac{f}{k_2 + f} \right)^2 \quad (3)$$

2.3. Detalhes de Implementação e Otimização Computacional

A prototipação inicial do algoritmo foi desenvolvida em linguagem Python. A escolha ocorreu por conta da sintaxe facilitada e da agilidade na manipulação estrutural da grade. No entanto, durante as validações preliminares, constatou-se que o algoritmo sofria de severos gargalos de desempenho.

Como a natureza do *Ant-Clustering* requer milhares de iterações, e cada agente precisa calcular repetidamente distâncias Euclidianas dentro de seu raio de percepção a cada passo, o *overhead* dos laços de repetição aninhados e a característica interpretada do Python tornaram o tempo de execução muito alto, cerca de 10 a 20 minutos (a depender dos parâmetros), para as bases de dados analisadas.

Para contornar essa limitação de tempo, a lógica central da simulação foi convertida para a linguagem C. A tipagem estática, aliada à execução nativa compilada e ao controle direto de memória do C, reduziu o tempo de processamento de forma drástica. Isso garantiu que as simulações complexas, envolvendo milhares de verificações para separar dados em 4 e 15 grupos distintos, fossem processadas com maior velocidade, cerca de 20 segundos a 1 minuto.

3. Descrição de Experimentos e Resultados Obtidos

Os experimentos foram conduzidos em duas etapas distintas para validar, primeiramente, a aglomeração espacial básica e, em seguida, a clusterização focada em características.

3.1. Cenário 1: Itens Homogêneos

Para a avaliação estritamente espacial, a simulação foi parametrizada com uma matriz de dimensões 50×50 , populada com 600 itens e operada simultaneamente por 50 agentes de coleta. O raio de percepção das formigas foi fixado em 1 (limitado às células imediatamente adjacentes).


A Figura 1 ilustra o estado final do ambiente após a convergência do algoritmo, evidenciando a formação topológica de múltiplos aglomerados densos a partir da distribuição aleatória inicial.

3.2. Cenário 2: Dados Heterogêneos (4 e 15 Grupos)


A avaliação de agrupamento não supervisionado com atributos numéricos utilizou dois conjuntos de dados distintos, previamente estruturados para conter, respectivamente, 4 e 15 agrupamentos lógicos. O processamento dessas instâncias foi realizado através das implementações desenvolvidas nativamente em linguagem C. Em ambos os testes, o raio de visão das formigas foi mantido em 1 e o algoritmo foi executado por 10.000.000 de iterações, operando com uma carga limite de até 1000 objetos.

Para garantir a coesão correta na separação dos grupos esperados, foi necessário calibrar empiricamente os hiperparâmetros e a dimensão do ambiente para cada conjunto de dados, adaptando a tolerância do sistema à distribuição dos elementos:

- **Cenário de 4 Grupos:** O ambiente operou em uma grade de 55×55 células, utilizando 25 agentes de coleta. As constantes de limiar para as ações de pegar e largar foram definidas como $k_1 = 0.05$ e $k_2 = 0.35$. O fator de tolerância da similaridade foi fixado em $\alpha = 0.6$.



(a) Estado Inicial



(b) Estado Final

Figura 1. Comparação da distribuição espacial: (a) disposição inicial aleatória e (b) formação dos agrupamentos após convergência.

- **Cenário de 15 Grupos:** O ambiente operou em uma grade ligeiramente menor, de 50×50 células, e reduziu-se o número de agentes para 10. Devido à necessidade de maior precisão para separar uma quantidade maior de aglomerados distintos, as constantes utilizadas foram $k_1 = 0.1$, $k_2 = 0.4$, exigindo uma similaridade restrita com $\alpha = 0.1$.

As Figuras 2 e 3 apresentam os agrupamentos resultantes, atestando a eficácia do método em segregar dados complexos através da métrica Euclidiana com a parametrização especificada.




Figura 2. Comparação da distribuição espacial: (a) disposição inicial aleatória e (b) formação dos agrupamentos após convergência.




Figura 3. Comparação da distribuição espacial: (a) disposição inicial aleatória e (b) formação dos agrupamentos após convergência.

4. Análise dos resultados obtidos.

A análise visual dos estados finais (Figuras 1, 2 e 3) comprova que o modelo estocástico baseado em heurísticas locais de P_{pegar} e P_{largar} é suficiente para induzir a organização global do ambiente.

No agrupamento homogêneo (Cenário 1), a restrição do raio de visão igual a 1 limitou a percepção global dos agentes. Como consequência, o sistema convergiu para a formação de múltiplos grupos menores e espalhados pela grade, em vez de um único e enorme grupo central. Esse comportamento reflete a fragmentação esperada quando as decisões de coleta e depósito (P_{pegar} e P_{largar}) são baseadas de forma puramente espacial e restritas à proporção direta de objetos presentes nas células imediatamente vizinhas.

Já no agrupamento heterogêneo (Cenário 2), o cálculo da similaridade por Distância Euclidiana demonstrou alta eficácia na separação topológica. Ao analisar os conjuntos de dados fornecidos, os agentes foram capazes de identificar as fronteiras entre as instâncias e organizar os elementos em seus respectivos agrupamentos lógicos (4 e 15 clusters, respectivamente).

Além da validação espacial, a reestruturação arquitetural da solução evidenciou o impacto da escolha da linguagem de programação na viabilidade de algoritmos de inteligência artificial de força bruta. A simulação inicial, desenvolvida em linguagem interpretada (Python), exigia um tempo proibitivo (10 a 20 minutos) devido ao *overhead* de interpretação nos laços aninhados que calculam a distância de cada vizinho. Ao migrar o núcleo de processamento para uma linguagem compilada (C), o tempo de execução foi reduzido para um intervalo de 20 segundos a 1 minuto, viabilizando as simulações mais densas com 15 grupos sem sacrificar a fidelidade do algoritmo.

5. Conclusões e Trabalhos Futuros

A aplicação prática do algoritmo de *Ant-Clustering* atingiu os objetivos propostos neste trabalho, demonstrando robustez tanto na organização espacial distribuída de itens homogêneos quanto no agrupamento não supervisionado de dados numéricos complexos. O comportamento convergente provou que o ajuste empírico dos limiares de coleta (k_1), depósito (k_2) e de tolerância à similaridade (α) é o fator determinante para ditar a rigidez das fronteiras dos grupos formados.

Do ponto de vista computacional, a migração da base de cálculo de uma linguagem interpretada para uma linguagem compilada comprovou ser uma etapa arquitetural indispensável para garantir a escalabilidade temporal da simulação frente à alta carga de processamento exigida pelo cálculo repetitivo de distâncias.

Como trabalhos futuros, sugere-se a automação do ajuste dos parâmetros k_1 e k_2 de forma adaptativa durante a execução, permitindo que o sistema se adeque dinamicamente a diferentes densidades de dados. Adicionalmente, propõe-se a experimentação com raios de percepção maiores (como raio 5). Para viabilizar esse aumento de campo visual sem comprometer o tempo de processamento, recomenda-se a implementação de estruturas de indexação espacial para otimizar a varredura da vizinhança dos agentes.

Referências

Lumer, E. D. e Faieta, B. (1994). Diversity and adaptation in populations of clustering ants. Em *Proceedings of the Third International Conference on Simulation of Adap-*

tive Behavior: From Animals to Animats 3, páginas 501–508. MIT Press.

Parpinelli, R. S. (2026). *02-IA-Agente Ant-Clustering e IA-Agrupamento*. Notas de aula da disciplina de Inteligência Artificial.